

Progetto di Basi di Dati

Federico Del Pup
Luigi Paşcu
Matteo Passador
Stefano Toneguzzo

20 maggio 2026

1 Indice

- **Glossario dei termini** (Sezione 2)
- **Strutturazione dei requisiti** (Sezione 3)
- **Tavola dei volumi** (Sezione 4)
- **Schema concettuale** (Sezione 5)
- **Schema logico** (Sezione 6)
- **Operazioni e Query** (Sezione 7)
- **Trigger** (Sezione 8)

2 Analisi dei requisiti

2.1 Introduzione alla richiesta

Il progetto richiede la progettazione di una base di dati relazionale per la gestione di una bibliografia, con un focus specifico sulle pubblicazioni accademiche. La base di dati deve essere in grado di gestire un ampio insieme di pubblicazioni, ciascuna caratterizzata da attributi specifici e relazioni complesse con autori, affiliazioni, editori, ecc. L'obiettivo è creare un modello concettuale che rappresenti fedelmente il dominio, seguito da una progettazione logica e fisica che ottimizzi le operazioni più frequenti, come la stampa dei dati e l'inserimento di nuove pubblicazioni. Inoltre, è richiesta l'implementazione di trigger per mantenere l'integrità dei dati e l'efficienza delle query, nonché la definizione di operazioni e query specifiche per l'analisi dei dati bibliografici.

2.2 Glossario dei termini

Termine	Descrizione	Collegamenti
Pubblicazione	Elemento di bibliografia	Autore, Pubblicazione
Articolo su rivista	Tipo di pubblicazione	Autore, Pubblicazione
Articolo per conferenza	Tipo di pubblicazione	Autore, Pubblicazione
Libro	Tipo di pubblicazione	Autore, Pubblicazione, Editor
Tesi	Tipo di pubblicazione	Autore, Pubblicazione, Università
Autore	Persona che scrive una pubblicazione	Pubblicazione, Affiliazione
Affiliazione	Gruppo di autori	Autore
Editore	Entità che pubblica un libro	Libro
Università	Luogo di discussione della tesi	Tesi

2.3 Strutturazione dei requisiti

2.3.1 Frasi di carattere generale

Si supponga di aver collezionato il seguente insieme di requisiti per la progettazione di una base di dati relazionale per la gestione di una bibliografia. Una bibliografia è costituita da un insieme di pubblicazioni.

2.3.2 Dettaglio dei requisiti

- **Pubblicazioni:** Ogni pubblicazione è caratterizzata da un codice univoco, un titolo, un anno di pubblicazione e uno o più autori. È presente una lista di riferimenti bibliografici (citazioni) verso altre pubblicazioni della bibliografia. Ogni pubblicazione tiene traccia del numero di citazioni ricevute.
- **Articoli su rivista:** Si registrano il nome della rivista, il numero del volume, le pagine (iniziale e finale) e il numero totale di pagine.
- **Articoli per conferenza:** Si registrano nome e luogo della conferenza, anno di svolgimento (indipendente dall'anno di pubblicazione), pagine (iniziale/finale) e totale pagine.
- **Libri:** Identificati dal codice ISBN, includono l'editore e il numero totale di pagine.
- **Tesi:** Si memorizzano l'argomento, l'università di discussione e il numero totale di pagine.
- **Autori:** Di ogni autore si memorizzano nome, cognome, email, pagina Web e una o più affiliazioni.
- **Affiliazioni:** Descritte da nome, indirizzo completo (via, civico, città, nazione) e numero di telefono.
- **Editori:** Descritti da nome e indirizzo fisico.
- **Università:** Identificate univocamente dal nome, includono indirizzo e telefono.

3 Progettazione concettuale

3.1 Gestione dell'entità Pubblicazione e delle sue specializzazioni

3.2 Gestione dell'entità Affiliazione e delle sue specializzazioni

3.3 Gestione della relazione Tesi-Affiliazione e di Autore




Figura 1: Schema Entità-Relazione

4 Progettazione logica

4.1 Tavola dei volumi

Concetto	Tipo	Volume
Pubblicazione	E	100.000
Articolo su rivista	E	20.000
Articolo per conferenza	E	15.000
Libro	E	10.000
Tesi	E	55.000
Autore	E	70.000
Affiliazione	E	500
Editore	E	400
Università	E	300
Ente di ricerca	E	200
Citazione	R	100.000×20
Scritto	R	$3,3 \times 100.000$
Appartenenza	R	70.000×2
Sede	R	55.000
Publica	R	10.000

La tavola dei volumi rappresenta il passaggio fondamentale dalla progettazione concettuale a quella logica, fornendo una stima quantitativa del carico che il database dovrà sostenere. Il sistema gestisce un totale di **100.000 pubblicazioni**. Si noti come la somma delle entità figlie (*Articolo su rivista*, *Articolo per conferenza*, *Libro*, *Tesi*) sia

esattamente pari a 100.000, riflettendo la scelta di una **gerarchia a copertura totale**. Le tesi rappresentano la quota maggioritaria (55.000), coerentemente con un dominio accademico.

La relazione **Citazione** è la più onerosa del sistema, con un volume stimato di **2.000.000 di record** (100.000×20). Questa dimensione giustifica l'introduzione dell'attributo derivato **NumeroCitazioni** per ottimizzare le operazioni di sola lettura, nonostante l'aggravio nei tempi di inserimento. In seguito viene mostrata un'analisi comparativa tra le due soluzioni, evidenziando i trade-off in termini di costo computazionale per le operazioni più frequenti. Con **70.000 autori** e una media di 3,3 autori per pubblicazione (relazione **Scritto**), il sistema deve gestire circa 330.000 legami autore-opera. La relazione **Appartenenza** (70.000×2) modella correttamente il turnover accademico, prevedendo che ogni autore sia mediamente affiliato a due enti diversi nel tempo. Il numero contenuto di **Affiliazioni (500)**, **Editori (400)** e **Università (300)** suggerisce che queste tabelle fungeranno da "anagrafiche di controllo", con un basso tasso di aggiornamento rispetto alle tabelle transazionali delle pubblicazioni e citazioni.

4.2 Analisi delle ridondanze

Frequenza delle Operazioni più comuni

Ecco una stima della frequenza delle operazioni più comuni che il sistema dovrà gestire, basata su ipotesi ragionevoli e coerenti con il dominio accademico:

OP1 Stampa delle pubblicazioni

Frequenza: 200/500 volte al giorno.

OP2 Inserimento e Aggiornamento

Inserire una pubblicazione (40 volte al giorno).

Aggiornamento delle citazioni di una pubblicazione (40 volte al giorno)

OP3 Inserire un autore

Frequenza: 10 volte al giorno.

OP4 Modifica autore/affiliazione

Frequenza: 1 volta al giorno (frequenza stimata).

Gli unici due attributi ridondanti presenti nello schema sono: **NumeroCitazioni** nell'entità **Pubblicazione** e **NumeroPagineTotali** nell'entità **Articolo**. Il primo è stato introdotto per ottimizzare le operazioni di stampa dei dati generali (*OP1*). Il secondo è superfluo, in quanto è possibile calcolarlo dinamicamente come differenza tra **PaginaFinale** e **PaginaIniziale** più uno. Di seguito viene mostrata un'analisi comparativa tra le due soluzioni per la prima ridondanza, evidenziando i trade-off in termini di costo computazionale per le operazioni più frequenti.

4.2.1 Con Ridondanza dell'attributo NumeroCitazioni

*Nota: Per il calcolo del costo, si assume che un accesso a un'entità o relazione di tipo "L" (lettura) abbia un costo unitario di 1, mentre un accesso di tipo "S" (scrittura) abbia un costo unitario di 2, riflettendo l'overhead aggiuntivo associato alle operazioni di scrittura rispetto a quelle di lettura. La stima del costo totale è effettuata con il dato di frequenza maggiore per ogni operazione, al fine di valutare l'impatto massimo della ridondanza sull'efficienza del sistema.

Operazione 1

Concetto	Costrutto	Accessi	Tipo
Pubblicazione	Entità	1	L

Costo: $(500 \times 1) \times 1 = 500$ unità di costo

Operazione 2

Concetto	Costrutto	Accessi	Tipo
Pubblicazione	Entità	2	S
Cita	Relazione	1	S
Pubblicazione	Entità	1	L
Autore	Entità	1	S

Passi logici:

- 1) Salvo i dati della pubblicazione
- 2) Salvo le coppie di pubblicazione e pubblicazione citata
- 3) Cerco la pubblicazione citata
- 4) Incremento di 1 il numero di citazioni a quella pubblicazione
- 5) Salvo la coppia pubblicazione autore

Costo: $(40 \times 4) \times 2 + (40 \times 1) \times 1 = 360$ unità

4.2.2 Senza Ridondanza dell'attributo NumeroCitazioni

Operazione 1

Concetto	Costrutto	Accessi	Tipo
Pubblicazione	Entità	1	L
Citazione	Relazione	20	L

Descrizione: Stampo i dati relativi ad una pubblicazione. Per ogni pubblicazione, per calcolare il numero di citazioni dobbiamo accedere in media alla relazione “citazione”, calcolato come: $\frac{\text{volume Citazione}}{\text{volume Pubblicazioni}} = 20$.

Costo: $500 \times (20 + 1) \times 1 = 10.500$ unità di costo

Operazione 2

Concetto	Costrutto	Accessi	Tipo
Pubblicazione	Entità	1	S
Cita	Relazione	1	S
Autore	Entità	1	S

Passi logici:

- 1) Salvo i dati della pubblicazione
- 2) Salvo le coppie di pubblicazione e pubblicazione citata
- 3) Salvo la coppia pubblicazione autore

Costo: $40 \times 3 \times 2 = 240$ unità di costo

4.2.3 Studio Comparativo

Costo	Presenza di ridondanza	Assenza di ridondanza
OP1	500	10.500
OP2	360	240
Totale	860	10.740

Conclusione: Poiché $860 < 10.740$, conviene mantenere l'attributo derivato.

4.3 Ristrutturazione dello schema ER




Figura 2: Schema ER modificato dopo la prima revisione

Specializzazione Rivista-Conferenza: La gerarchia è stata accorpata verso l'alto (ri-strutturazione verso il padre) eliminando le entità figlie e migrandone gli attributi nell'entità genitore *Articolo*. Per distinguere le occorrenze, è stato introdotto l'attributo discriminante *Tipo*, i cui valori sono vincolati al dominio {Rivista, Conferenza}.

Gli attributi derivanti dalle classi figlie sono stati definiti come opzionali (cardinalità 0..1), con l'eccezione dell'attributo *Nome*, che rimane obbligatorio in quanto comune a entrambe le tipologie. Si specifica, inoltre, che l'attributo *AnnoConferenza* deve essere semanticamente distinto dall'attributo *AnnoPubblicazione*.




Figura 3: Schema ER modificato dopo la seconda revisione

Semplificazione della Gerarchia Affiliazione: La specializzazione tra l'entità *Affiliazione* (padre) e le sottoclassi *Università* ed *Ente di Ricerca* è stata risolta mediante l'accorpamento verso il padre. Tale scelta è motivata dall'assenza di attributi specifici rilevanti nelle entità figlie.

Per preservare la semantica originale, è stato introdotto un vincolo di integrità basato sul tipo di affiliazione: l'associazione con l'entità *Tesi* è valida esclusivamente per le occorrenze di tipo *Università*. In termini di cardinalità, il rapporto tra *Tesi* ed *Affiliazione* è di $(1, 1)$, mentre la partecipazione dell'entità *Affiliazione* è $(0, n)$, poiché solo il sottoinsieme relativo alle università può essere associato a una tesi.

Semplificazione dell'attributo Indirizzo: L'attributo composto *Indirizzo Fisico* è stato ristrutturato mediante un processo di aggregazione dei suoi componenti (quali via, numero civico, CAP e città). Al fine di semplificare l'implementazione nel modello logico e facilitare le operazioni di inserimento, i singoli campi sono stati unificati in un unico attributo atomico di tipo stringa.




Figura 4: Schema ER modificato dopo la terza revisione

Risoluzione della Gerarchia Pubblicazione: La specializzazione tra l'entità genitore *Pubblicazione* e le sottoclassi *Articolo*, *Libro* e *Tesi* è stata risolta mantenendo le entità distinte (strategia delle entità multiple).

Per implementare correttamente il legame logico, sono state definite relazioni esplicite tra il padre e i figli tramite l'uso di chiavi esterne (*foreign keys*) nelle entità figlie che referenziano la chiave primaria di *Pubblicazione*. Al fine di garantire la copertura totale della specializzazione, è stato introdotto un vincolo di integrità aggiuntivo: ogni occorrenza dell'entità *Pubblicazione* deve necessariamente essere referenziata come chiave esterna in almeno una delle tre entità figlie.




Figura 5: Schema ER modificato dopo la quarta revisione

Ristrutturazione della relazione "Scritto" e "Appartenenza": La relazione *Scritto* è stata ristrutturata in modo da inserire un'entità associativa, denominata *Pubb-Autori*, che collega l'entità *Autore* con l'entità *Pubblicazione*. Questa scelta è motivata dalla necessità di rappresentare correttamente la relazione multi-a-molti tra autori e pubblicazioni, consentendo di gestire efficacemente i casi in cui una pubblicazione abbia più autori e un autore abbia più pubblicazioni. Lo stesso approccio è stato adottato per la relazione *Appartenenza*, con l'introduzione dell'entità associativa *Aut-Aff* che collega l'entità *Autore* con l'entità *Affiliazione*. Questa ristrutturazione consente di modellare in modo più flessibile le dinamiche di affiliazione degli autori, che possono essere associati a più enti nel tempo, e di mantenere una chiara tracciabilità delle relazioni tra autori e affiliazioni.




Figura 6: Schema ER finale senza le modifiche di dettaglio

4.4 Schema logico

Dal moodello ER finale, si ottiene lo schema logico relazionale seguente:
PUBBLICAZIONI(Codice, Titolo, Anno, NumeroCitazioni)

ARTICOLI(CodicePubblicazione, Nome, NumeroRivista, LuogoRivista, Anno, PaginaIniziale, PaginaFinale, Tipo)
 LIBRI(CodicePubblicazione, ISBN, NumeroPagine, NomeEditore)
 TESI(CodicePubblicazione, Argomento, NumeroPagine, Affiliazione)
 AUTORI(ID, Nome, Cognome, Email, SitoWeb)
 AFFILIAZIONI(Nome, IndirizzoFisico, NumeroTelefono, Tipo)
 EDITORI(Nome, Indirizzo)
 CITAZIONI(PubblicazioneChiamante, PubblicazioneCitata)
 PUBB-AUTORI(IDAutore, CodicePubblicazione)
 AUT-AFF(IDAutore, NomeAffiliazione)

*le chiavi primarie sono sottolineate, mentre le chiavi esterne sono indicate con frecce.

Chiavi esterne:

ARTICOLI.CodicePubblicazione → PUBBLICAZIONI.Codice
 LIBRI.CodicePubblicazione → PUBBLICAZIONI.Codice
 TESI.CodicePubblicazione → PUBBLICAZIONI.Codice
 CITAZIONI.PubblicazioneChiamante → PUBBLICAZIONI.Codice
 CITAZIONI.PubblicazioneCitata → PUBBLICAZIONI.Codice
 LIBRI.NomeEditore → EDITORI.Nome
 TESI.Affiliazione → AFFILIAZIONI.Nome
 PUBB-AUTORI.IDAutore → AUTORI.ID
 PUBB-AUTORI.CodicePubblicazione → PUBBLICAZIONI.Codice
 AUT-AFF.IDAutore → AUTORI.ID
 AUT-AFF.NomeAffiliazione → AFFILIAZIONI.Nome

Si noti che le chiavi primarie sono state definite in modo da garantire l'univocità di ogni record, mentre le chiavi esterne sono state implementate per mantenere l'integrità referenziale tra le tabelle, assicurando che le relazioni logiche tra i dati siano rispettate. L'unica chiave candidabile non scelta come chiave primaria è l'ISBN nella tabella **LIBRI**, poiché il codice della pubblicazione è già un identificatore univoco sufficiente per distinguere ogni libro all'interno del sistema. Si è preferito mantenere un'unica chiave primaria per semplificare le operazioni di join e ridurre la complessità del modello, evitando la necessità di gestire chiavi composite o multiple per la stessa entità.

5 Progettazione fisica (Implementazione DB)

5.1 Generazione delle tabelle SQL

5.2 Popolamento del database

5.3 Trigger

Trigger per l'aggiornamento del numero di citazioni

Non Autocitazione: Una pubblicazione non può citare sé stessa. Questo è il vincolo più elementare e serve a prevenire l'inserimento di dati logicamente inconsistenti, garantendo che il conteggio delle citazioni rifletta solo i riferimenti esterni.

Non Citazione Circolare: Una pubblicazione A non può citare una pubblicazione B se B cita già A, direttamente o indirettamente. Questo vincolo impedisce la formazione di

cicli di citazione che potrebbero distorcere il conteggio delle citazioni e complicare l'analisi bibliometrica.

Nota sul Vincolo Temporale: Una pubblicazione non può citare un'altra pubblicazione con un anno di pubblicazione successivo. Pur riconoscendo l'esistenza di casi come i preprint nel mondo reale, per coerenza logica del modello e per semplicità, questo vincolo è assunto come rilevante e implementato nel database.

6 Query

OP5 Autore con più pubblicazioni per affiliazione

Stampare il nome dell'autore che detiene il maggior numero di pubblicazioni per ogni singola affiliazione.

OP6 Co-autoria esclusiva

Stampare le coppie di autori che hanno collaborato sempre e solo tra di loro (ovvero, ogni loro pubblicazione è stata fatta in coppia).

OP7 Autori fedeli all'affiliazione

Stampare gli autori che non hanno mai prodotto pubblicazioni con co-autori appartenenti a un'affiliazione diversa dalla propria.

OP8 Analisi dell'impatto a breve termine

Trovare gli autori che hanno pubblicato esclusivamente articoli i quali, a distanza di 2 anni dalla data di pubblicazione, hanno accumulato almeno 5 citazioni.

OP5: Autore con più pubblicazioni per ogni affiliazione

```
SELECT a.nome, a.cognome, aa.nome_affiliazione
FROM AUTORE a
JOIN PUBB_AUTORE pa ON a.id = pa.id_autore
JOIN AUTO_AFF aa ON a.id = aa.id_autore
GROUP BY a.id, a.nome, a.cognome, aa.nome_affiliazione
HAVING COUNT(pa.codice_pubblicazione) = (
    SELECT MAX(cnt)
    FROM (
        SELECT COUNT(pa2.codice_pubblicazione) AS cnt
        FROM AUTORE a2
        JOIN PUBB_AUTORE pa2 ON a2.id = pa2.id_autore
        JOIN AUTO_AFF aa2 ON a2.id = aa2.id_autore
        WHERE aa2.nome_affiliazione = aa.nome_affiliazione
        GROUP BY a2.id
    ) sub
);
```

OP6: Coppie che hanno pubblicato sempre e solo insieme

```

SELECT pa1.id_autore , pa2.id_autore
FROM PUBB_AUTORE pa1
JOIN PUBB_AUTORE pa2
    ON pa1.codice_pubblicazione = pa2.codice_pubblicazione
    AND pa1.id_autore < pa2.id_autore
GROUP BY pa1.id_autore , pa2.id_autore
HAVING COUNT(DISTINCT pa1.codice_pubblicazione) = (
    SELECT COUNT(*)
    FROM PUBB_AUTORE pa
    WHERE pa.id_autore = pa1.id_autore
)
AND COUNT(DISTINCT pa2.codice_pubblicazione) = (
    SELECT COUNT(*)
    FROM PUBB_AUTORE pa
    WHERE pa.id_autore = pa2.id_autore
);

```

OP7: Autori che non hanno mai pubblicato con colleghi di altre affiliazioni

Un autore è valido se NON esiste nessuna pubblicazione in cui ha collaborato con un autore di affiliazione diversa.

```
SELECT a.id, a.nome, a.cognome
FROM AUTORE a
WHERE NOT EXISTS (
    SELECT 1
    FROM PUBB_AUTORE pa1
    JOIN PUBB_AUTORE pa2
        ON pa1.codice_pubblicazione = pa2.codice_pubblicazione
        AND pa1.id_autore <> pa2.id_autore
    JOIN AUTO_AFF aa1
        ON aa1.id_autore = pa1.id_autore
    JOIN AUTO_AFF aa2
        ON aa2.id_autore = pa2.id_autore
    WHERE pa1.id_autore = a.id
        AND aa1.nome_affiliazione <> aa2.nome_affiliazione
);
```

OP8: Autori con solo articoli di successo (min. 5 citazioni a 2 anni)

```
SELECT a.id, a.nome, a.cognome
FROM public.autore a
-- Condizione A: L'autore deve aver pubblicato almeno un articolo
WHERE EXISTS (
    SELECT 1 FROM public.pubb_autore pa WHERE pa.id_autore = a.id
)
-- Condizione B: NON deve esistere alcuna sua pubblicazione "flop"
AND NOT EXISTS (
    SELECT 1
    FROM public.pubb_autore pa
    JOIN public.pubblicazione p ON pa.codice_pubblicazione = p.
        ↳ codice
    WHERE pa.id_autore = a.id
        AND (
            SELECT COUNT(*)
            FROM public.citazione c
            JOIN public.pubblicazione pc ON c.
                ↳ codice_pubblicazione_citante = pc.codice
            WHERE c.codice_pubblicazione_citata = p.codice
                AND (pc.annopubblicazione - p.annopubblicazione) <= 2
        ) < 5
);
```

Nota sull'inefficacia dell'attributo derivato nella query OP8: Nonostante la presenza dell'attributo derivato NumeroCitazioni nell'entità **PUBBLICAZIONE** — intro-

dotto per ottimizzare la stampa dei dati generali (*OP1*) — esso risulta inutilizzabile ai fini della query **OP8** (*Analisi dell'impatto a breve termine*).

Il limite risiede nella natura stessa dell'attributo ridondante:

- **Staticità del dato:** L'attributo memorizza esclusivamente il conteggio totale e cumulativo delle citazioni ricevute fino all'istante attuale.
- **Vincolo Temporale Dinamico:** La specifica della *OP8* richiede il filtraggio delle sole citazioni avvenute entro un arco temporale di **due anni** dalla data di rilascio della pubblicazione.

Di conseguenza, per soddisfare il requisito, è necessario ignorare il valore pre-calcolato ed effettuare un calcolo dinamico accedendo direttamente alla relazione **CITAZIONI**. Questo processo permette di confrontare gli attributi **Anno** della pubblicazione citante e di quella citata, operazione indispensabile per isolare il sottoinsieme di riferimenti bibliografici pertinenti all'analisi richiesta.